

REPORTE TÉCNICO Y ESTRATÉGICO

Sistema Estocástico de Gestión de Riesgo y Capacidad de
Proveedores

Temporada Alta Demanda: Julio – Diciembre 2026

Johanna Camila Willis Ruiz

Ingeniería en Ciencia de Datos y Matemáticas
Tecnológico de Monterrey, Campus Guadalajara
Bloque: Organizaciones Resilientes 2026

1. Resumen Ejecutivo y Planteamiento del Problema

Este reporte documenta el diseño, implementación y resultados de un motor matemático de simulación estocástica construido para analizar la capacidad de abastecimiento de los proveedores de una empresa de venta al detalle de calzado en México. El sistema proyecta la demanda, cuantifica el riesgo de desabasto y genera recomendaciones cuantitativas de inventario de seguridad para cada proveedor activo durante la temporada julio–diciembre 2026.

El análisis parte de una base de datos transaccional de ventas y pedidos negados correspondiente al periodo julio 2023 – diciembre 2025. Tras aplicar los filtros de negocio pertinentes (origen nacional, categoría calzado, tipo bota), se retienen 448,980 registros distribuidos entre 33 proveedores activos en 5 sucursales. Cada registro incluye: semana, fecha, año, proveedor, modelo, origen (nacional/importación), catálogo, tipo, talla, sucursal, unidades vendidas y unidades negadas.

La empresa enfrenta un problema estructural de desabasto recurrente durante la temporada alta: un porcentaje significativo de la demanda real no puede ser atendida porque el inventario se agota antes de que llegue el reabastecimiento. El impacto directo es la pérdida de ventas; el impacto indirecto es la erosión de la experiencia de compra del cliente. Este problema no se distribuye uniformemente entre proveedores, algunos fallan de manera crónica mientras otros mantienen tasas de cumplimiento superiores al 99%.

El objetivo central del proyecto es responder tres preguntas de negocio accionables:

- ¿Cuáles proveedores representan el mayor riesgo de desabasto en la temporada Jul–Dic 2026 y por qué?
- ¿Cuánto inventario de seguridad adicional debe negociarse con cada proveedor, mes a mes, para garantizar un nivel de servicio del 95%?
- ¿Cuánto riesgo y cuántas ventas perdidas se recuperarían si parte del volumen de proveedores problemáticos se transfiriera al pool de proveedores estrella?

1.1 Contexto del Negocio y la Base de Datos

La empresa opera un modelo de venta al detalle donde el inventario en tienda depende directamente de la capacidad de surtido de sus proveedores. Cuando un proveedor no puede cumplir con el volumen pedido, la tienda registra unidades 'negadas': clientes que solicitaron el producto y no pudieron comprarlo por ausencia de stock.

Un aspecto crítico del modelo de negocio es que no todas las unidades negadas representan ventas perdidas netas para la empresa. Ante un quiebre de stock en un modelo específico de bota, el comportamiento del cliente puede ser:

- Compra de un producto sustituto dentro de la misma tienda (comportamiento más frecuente, estimado en el 75% de los casos según conocimiento del negocio compartido por la empresa).
- Abandono de la tienda sin comprar (pérdida neta de venta, estimada en el 25% restante).

Este parámetro, denominado `FACTOR_NEGADOS` = 0.25, es el insumo de dominio más importante del modelo. Determina cómo se reconstruye la demanda real a partir de las ventas observadas y los registros de negados, y fue provisto directamente por la empresa como estimación operativa basada en observación histórica del comportamiento de sus clientes.

1.2 Restricción Central del Análisis: $N = 3$

El reto analítico más importante del proyecto no es la escasez de registros totales, 448,980 transacciones es un volumen considerable, sino la profundidad temporal del análisis por celda proveedor-mes.

Al aislar el comportamiento de un proveedor específico en un mes específico (por ejemplo, PROV48 en noviembre), la muestra histórica disponible se reduce exactamente a los periodos homólogos: noviembre 2023, noviembre 2024 y noviembre 2025. El tamaño efectivo de la serie temporal es $N = 3$.

Esta restricción tiene consecuencias metodológicas fundamentales. Cualquier técnica estadística o de machine learning diseñada para series largas produce resultados inestables o directamente inválidos con $N = 3$:

- SARIMA y ARIMAX: requieren estimación de parámetros estacionales con mínimo 30–50 observaciones para que los coeficientes sean estadísticamente significativos. Con $N = 3$, el modelo memoriza los datos sin capacidad predictiva real.
- Redes neuronales recurrentes (LSTM, GRU): requieren cientos o miles de secuencias de entrenamiento. Con 3 puntos, el modelo overfittea perfectamente sin aprender ningún patrón generalizable.
- Gradient Boosting y Random Forest: diseñados para datos tabulares amplios. Con $N = 3$ como variable objetivo, producen modelos degenerados.
- Bootstrap no paramétrico: solo puede remuestrear combinaciones de los 3 puntos existentes; no puede simular escenarios fuera del rango histórico observado, lo cual es precisamente lo que se necesita para recomendaciones conservadoras de inventario de seguridad.

La decisión metodológica de usar simulación Monte Carlo paramétrica no es una concesión a la falta de datos, es la respuesta técnicamente correcta a esta clase de problema. Monte Carlo aprovecha los 3 puntos para ajustar una distribución de probabilidad y luego genera 10,000 escenarios sintéticos que respetan la forma estadística de esa distribución, cuantificando la incertidumbre de manera honesta y explícita en lugar de ocultarla.

1.3 Escalabilidad del Modelo

El pipeline está diseñado para escalar automáticamente con más datos históricos sin modificar una sola línea de código. El impacto concreto de agregar años de historia sería:

- Con $N = 5-7$ años por celda: los parámetros de la distribución ajustada (media, varianza) convergerían más rápidamente; los intervalos de incertidumbre P5–P95 se angostarían

considerablemente; la probabilidad de desabasto sería más diferenciada entre proveedores, evitando la concentración actual en el rango 50–100%.

- Con $N = 8\text{--}10$ años: el Walk-Forward Cross-Validation tendría suficientes folds para estimar el parámetro α con mayor precisión estadística; sería posible detectar ciclos plurianuales de demanda que el modelo actual no puede capturar.
- Con datos de SKU completos (modelo \times proveedor \times mes): el análisis podría descender al nivel de modelo de zapato, permitiendo recomendaciones de stock de seguridad por SKU en lugar de por proveedor total.

La recomendación operativa es actualizar las simulaciones trimestralmente conforme se acumula más historia transaccional, convirtiendo el modelo en una herramienta de uso continuo en lugar de un análisis de una sola vez.

2. Arquitectura del Pipeline Analítico

El sistema está implementado como un pipeline Python de ocho módulos funcionales ejecutados secuencialmente. Cada módulo recibe un input bien definido, aplica una transformación matemática y entrega un output concreto al módulo siguiente. Esta arquitectura modular garantiza reproducibilidad total, facilidad de mantenimiento y escalabilidad futura.

Módulo	Función Principal	Input	Output
cargar_datos()	Ingesta, limpieza y filtrado de la base original	CSV transaccional raw	DataFrame filtrado Jul-Dic con demanda reconstruida
calcular_metricas()	Radiografía histórica del portafolio de proveedores	DataFrame limpio + alpha	Tabla de riesgo con score, FR y clasificación por proveedor
cross_validate_pesos()	Optimización del hiperparámetro alpha por Walk-Forward CV	DataFrame + rango de alpha de 0 a 1	alpha óptimo y rho de Spearman validado
ajustar_distribucion()	Selección de distribución estadística por MLE y AIC	Serie numérica (N >= 1)	Nombre de distribución óptima y sus parámetros ajustados
simular_proveedor_estacional()	Motor Monte Carlo por proveedor y mes (Jul-Dic)	Datos históricos del proveedor	10,000 escenarios de exceso de demanda por mes
simular_transferencia_volumen()	Análisis what-if de transferencia de volumen entre proveedores	Escenarios del proveedor de alto riesgo + datos del proveedor estrella	Reducción de riesgo y volumen de ventas recuperado
plot_*	Generación de visualizaciones diagnósticas por proveedor y portafolio	Resultados de simulación + métricas históricas	Gráficos PNG: dashboards por proveedor, heatmaps, curvas CV
generar_tablas()	Exportación de resultados en formato tabular para uso operativo	Todos los resultados consolidados	3 archivos CSV entregables listos para uso del equipo de compras

El pipeline corre de extremo a extremo en aproximadamente 2–5 minutos dependiendo del hardware, procesando los 33 proveedores de manera secuencial con 10,000 iteraciones de Monte Carlo por proveedor por mes (198,000 simulaciones individuales en total para los 6 meses de la temporada).

3. Fundamentos Matemáticos y Estadísticos

Esta sección documenta en detalle la base matemática de cada componente del sistema. El objetivo es que cualquier analista pueda auditar, replicar y extender el modelo a partir de esta documentación.

3.1 Reconstrucción de la Demanda Real: Demanda Censurada

Los datos transaccionales registran ventas concretadas, no la demanda total latente del mercado. Este fenómeno se conoce estadísticamente como datos censurados por la izquierda: se observa lo que se pudo vender, pero no necesariamente lo que se habría vendido si hubiera habido suficiente inventario.

Cuando un cliente llega a la tienda y el producto está agotado (unidad negada), ocurre una de dos cosas: el cliente compra un sustituto (la venta se concreta pero con otro proveedor o modelo) o el cliente se va sin comprar (venta perdida neta). Si el modelo usara solo las ventas brutas como proxy de demanda, subestimaría sistemáticamente la demanda real y produciría recomendaciones de stock de seguridad insuficientes.

La corrección aplicada es:

$$\text{Demanda_Real} = \text{Ventas} + (\text{Negados} \times \text{FACTOR_NEGADOS})$$

$$\text{Demanda_Real} = \text{Ventas} + (\text{Negados} \times 0.25)$$

El parámetro $\text{FACTOR_NEGADOS} = 0.25$ fue provisto por la empresa como estimación operativa: el 75% de los clientes que encuentran un artículo agotado compran un sustituto en la misma tienda (esa venta no se pierde para la empresa, aunque sí para el proveedor específico), y el 25% restante abandona la tienda sin comprar, representando pérdida neta de demanda que debe ser incorporada al modelo de capacidad del proveedor.

Este ajuste es conceptualmente importante porque define cómo se asigna responsabilidad: un negado no es culpa de la tienda sino del proveedor que no pudo surtir el pedido. La demanda real reconstruida representa lo que el mercado efectivamente hubiera absorbido si el proveedor hubiera cumplido al 100%.

3.2 Score de Riesgo Compuesto por Proveedor

Para clasificar a los 33 proveedores según su historial de confiabilidad se construye un score compuesto que combina dos señales independientes de riesgo:

Componente 1: Tasa de Negados (Fulfillment Gap)

$$\text{Fulfillment_Rate} = \text{Ventas_Total} / \text{Demanda_Total_Ajustada}$$

$$\text{Tasa_Negados} = 1 - \text{Fulfillment_Rate}$$

El Fulfillment Rate mide qué fracción de la demanda real fue efectivamente cubierta por el proveedor a lo largo de todo su historial. Una tasa de negados de 0.223 (como en PROV44) significa que el proveedor no pudo cubrir el 22.3% de lo que el mercado le pedía, aproximadamente 1 de cada 4.5 unidades demandadas quedó sin surtir.

Componente 2: Coeficiente de Variación (Volatilidad de la Demanda)

$$\text{CV} = \text{sigma_demanda} / \text{mu_demanda}$$

El Coeficiente de Variación mide la dispersión relativa de la demanda histórica del proveedor. Un proveedor con demanda muy irregular mes a mes es más difícil de planear logísticamente aunque su cumplimiento promedio sea alto, la incertidumbre sobre cuánto va a pedir la tienda hace más difícil que el proveedor mantenga el inventario correcto.

Score Compuesto y Parámetro Alpha

$$\text{Score_Riesgo} = \alpha \times \text{Tasa_Negados} + (1 - \alpha) \times \text{CV}$$

El parámetro alpha controla el peso relativo de cada componente. $\alpha = 1.0$ significa que solo importa la tasa de negados histórica; $\alpha = 0.0$ significa que solo importa la volatilidad. El valor óptimo ($\alpha = 0.95$) fue determinado mediante validación cruzada y confirma que la Tasa de Negados es el predictor dominante del riesgo futuro, la volatilidad aporta una señal marginal pero el historial de cumplimiento concentra casi toda la información predictiva.

Clasificación en Tres Niveles de Riesgo

Los 33 proveedores se clasifican en tres grupos mediante percentiles adaptativos calculados sobre la distribución real de scores:

$$\begin{aligned} \text{BAJO} &\rightarrow \text{Score} \leq P33 \quad (\text{scores} < 0.087) \\ \text{MEDIO} &\rightarrow P33 < \text{Score} \leq P66 \quad (0.087 \leq \text{scores} < 0.131) \\ \text{ALTO} &\rightarrow \text{Score} > P66 \quad (\text{scores} > 0.131) \end{aligned}$$

El uso de percentiles adaptativos en lugar de umbrales fijos garantiza que siempre hay exactamente 11 proveedores en cada categoría (33% en cada nivel), independientemente de la distribución de scores del portafolio analizado. Esto evita el problema de clasificaciones degeneradas donde todos los proveedores caen en el mismo nivel.

3.3 Validación Cruzada Walk-Forward y Optimización de Alpha

La determinación del valor óptimo de alpha no se hace por intuición o prueba manual, se hace mediante validación cruzada sobre los datos históricos reales, siguiendo un esquema temporal estricto.

Por qué Walk-Forward y no K-Fold clásico

El K-Fold Cross-Validation clásico aleatoriza las observaciones entre folds de entrenamiento y validación. En datos de series temporales esto viola la causalidad fundamental: el modelo podría 'ver' datos de julio 2025 para predecir el comportamiento de julio 2023. Walk-Forward garantiza que el modelo siempre entrena en el pasado y valida en el futuro real, exactamente como se usaría en producción.

Esquema de Validación con N = 3 años

- Fold 1: Entrena con datos de 2023 completo. Valida prediciendo el comportamiento de riesgo en 2024.
- Fold 2: Entrena con datos de 2023 y 2024 combinados. Valida prediciendo el comportamiento de riesgo en 2025.

En cada fold, para cada valor de alpha probado (desde 0.00 hasta 1.00 en pasos de 0.05), el sistema calcula el Score_Riesgo con el conjunto de entrenamiento y luego evalúa si ese score predice correctamente la Tasa_Negados del periodo de validación.

Métrica de Evaluación: Correlación de Rangos de Spearman

$$\rho = 1 - (6 \times \text{Sum}(di^2)) / (n \times (n^2 - 1))$$

Donde di es la diferencia de rangos entre el score histórico del proveedor i y su tasa de negados futura. Se usa el coeficiente de Spearman (no el de Pearson) deliberadamente: el objetivo no es predecir el valor exacto de la falla futura, sino garantizar que el ranking de riesgo se preserve correctamente en el tiempo. Si el modelo dice que PROV44 es más riesgoso que PROV16, ese orden debe mantenerse en el periodo de validación, independientemente de la magnitud exacta de los valores.

Resultado de la Validación

El modelo convergió a alpha = 0.95 con rho = 0.30 promedio entre folds. Este resultado tiene una interpretación clara:

- La Tasa de Negados es el predictor dominante del riesgo futuro (alpha = 0.95 vs 0.05 para CV).
- Una correlación de Spearman de rho = 0.30 en entornos de alta volatilidad con N = 3 observaciones representa una señal predictiva válida y estadísticamente superior al azar puro (rho = 0). No es un modelo perfecto, no puede serlo con 3 puntos, pero sí confirma que los proveedores más riesgosos hoy tienden a ser los más riesgosos mañana.
- La señal predictiva de 0.30 justifica metodológicamente usar el score histórico como base para las decisiones de inventario 2026.

3.4 Ajuste Dinámico de Distribuciones por Criterio AIC

Para cada combinación proveedor × mes (198 celdas en total: 33 proveedores × 6 meses), el sistema ajusta automáticamente la distribución estadística más apropiada a los datos históricos

disponibles usando Estimación por Máxima Verosimilitud (MLE) y selección por Criterio de Información de Akaike (AIC).

Criterio de Información de Akaike (AIC)

$$AIC = 2k - 2 \times \ln(L^{\wedge})$$

Donde k es el número de parámetros del modelo y L^{\wedge} es la verosimilitud máxima alcanzada. El AIC penaliza la complejidad del modelo: si dos distribuciones ajustan los datos de manera similar, el AIC favorece la más parsimoniosa (la que tiene menos parámetros). Se elige la distribución que minimiza el AIC.

Distribuciones Candidatas

Normal $N(\mu, \sigma)$: Apropriada cuando los datos son aproximadamente simétricos alrededor de la media y la varianza no depende de la magnitud. Parámetros: media μ y desviación estándar σ (2 parámetros $\rightarrow k = 2$).

Gamma $G(\alpha, \beta, \text{loc}=0)$: Distribución estándar en gestión de inventarios estocásticos. Dominio estrictamente positivo ($x > 0$), evita demandas negativas imposibles y modela naturalmente la asimetría positiva característica de los picos de compra. Se fuerza el parámetro de locación a cero ($\text{floc} = 0$) para garantizar que el dominio empiece en cero. Tres parámetros formalmente, pero con $\text{floc} = 0$ fijo efectivamente son 2 parámetros libres ($k = 2$ al igual que Normal), lo que hace la comparación AIC directamente válida.

La distribución ganadora y sus parámetros ajustados quedan documentados en la columna DIST_DEMANDA de la tabla de predicción para cada proveedor y mes.

3.5 Motor de Simulación Monte Carlo Estacional

El componente central del sistema. Para cada proveedor p y cada mes m en {Julio, Agosto, Septiembre, Octubre, Noviembre, Diciembre}, el algoritmo ejecuta los siguientes pasos:

Paso 1: Construcción de Series Históricas

```
Serie_Demanda(p,m) = {D_Real(p,m,2023), D_Real(p,m,2024),  
                      D_Real(p,m,2025)}  
  
Serie_Capacidad(p,m) = {Ventas(p,m,t) : Negados(p,m,t) = 0, t en  
                       {2023,2024,2025}}
```

La capacidad del proveedor se estima exclusivamente de los periodos sin negados. La lógica es que si no hubo quiebre de stock en ese mes-año, las ventas observadas representan la demanda satisfecha sin restricción de capacidad, es decir, el proveedor pudo surtir todo lo que se le pidió. Si en todos los años disponibles hubo negados para ese proveedor-mes (desabasto crónico), se aplica el buffer de capacidad latente descrito en la Sección 4.2.

Paso 2: Ajuste de Distribuciones

Se ajustan distribuciones independientes para la serie de demanda y para la serie de capacidad del proveedor-mes usando el método AIC descrito en la Sección 3.4.

Paso 3: Generación de 10,000 Escenarios

```
D_sim[i] ~ Dist_Demanda(params_dem), i = 1,...,10000
C_sim[i] ~ Dist_Capacidad(params_cap), i = 1,...,10000
Exceso[i] = max(0, D_sim[i] - C_sim[i])
```

Cada uno de los 10,000 escenarios representa un posible estado del mundo en 2026: una demanda particular del mercado en ese mes y una capacidad particular del proveedor para responder a ella. El exceso de demanda sobre capacidad representa las unidades que el proveedor no podría cubrir en ese escenario.

Paso 4: Cálculo de Métricas de Salida

```
Demanda_Esperada = (1/10000) x Sum(D_sim[i])
Prob_Desabasto = #{Exceso[i] > 0} / 10000
Stock_Seguridad_P95 = Percentil_95(Exceso)
```

La Probabilidad de Desabasto es la fracción de los 10,000 escenarios donde el proveedor no puede cubrir la demanda completamente. El Stock de Seguridad en el percentil 95 significa que si la empresa mantiene ese nivel de inventario adicional, estará cubierta en el 95% de los universos posibles simulados. Usar la media del exceso (P50) solo garantizaría cobertura el 50% de las veces, equivalente a lanzar una moneda para decidir si habrá desabasto o no.

3.6 Análisis de Tendencia Interanual

Además de la variabilidad aleatoria capturada por Monte Carlo, el modelo incorpora una componente de tendencia secular para capturar si la demanda de cada proveedor está creciendo o declinando año sobre año.

```
Tendencia(p,m) = beta_1 donde y_t = beta_0 + beta_1 x t con t =
{2023, 2024, 2025}
```

La pendiente β_1 de la regresión lineal simple (OLS) sobre los tres puntos históricos indica cuántas unidades adicionales (o menos) se demandaron por año. Sin embargo, con solo $N = 3$ observaciones, esta pendiente puede ser extremadamente inestable, un solo año atípico puede producir una tendencia proyectada irreal. Para controlar este riesgo:

```
Tendencia_Acotada = clip(Tendencia_cruda, -0.20 x mu_hist, +0.20 x
mu_hist)
```

El clipping limita la tendencia proyectada a un máximo del $\pm 20\%$ de la media histórica mensual del proveedor. Esto equivale a asumir que la demanda puede crecer o caer como máximo un 20% interanual, supuesto razonable y conservador para un horizonte de un año en el sector calzado.

4. Heurísticas y Reglas de Control del Modelo

Al modelar procesos estocásticos con muestras muy pequeñas ($N = 3$), la matemática pura puede generar valores incontrolables en las colas de las distribuciones. Las tres reglas de control descritas en esta sección actúan como anclas de realismo operativo que impiden que escenarios extremos estadísticamente posibles pero operativamente absurdos distorsionen las recomendaciones de inventario.

4.1 Cap de Cola Larga: Límite de 5 Veces la Media

La distribución Gamma con parámetros de forma pequeños (alta varianza relativa) y $N = 3$ observaciones puede generar, en la cola derecha de la distribución, valores decenas de veces superiores a la media histórica. Un único escenario extremo entre los 10,000 puede elevar artificialmente el percentil P95 a valores no operativos.

Para contener este problema se aplica un techo al exceso de demanda simulado:

```
Exceso_capado[i] = min(Exceso[i], 5 x mu_demanda_historica_mensual)
```

Este límite establece que ningún escenario de exceso puede superar 5 veces la demanda media histórica del proveedor en ese mes. El supuesto implícito es que el mercado de calzado no puede crecer más de 5 veces su nivel promedio en un horizonte de un año, un supuesto conservador razonable incluso en escenarios de crecimiento extraordinario o campaña de marketing agresiva.

4.2 Buffer de Capacidad Latente para Desabasto Crónico

Algunos proveedores presentan historial de desabasto crónico: nunca tuvieron un mes sin ningún negado, por lo que la serie de capacidad (construida solo a partir de meses sin negados) está vacía. Este fenómeno se conoce estadísticamente como datos censurados por la derecha: se sabe que la capacidad real es mayor o igual a las ventas observadas, pero no se conoce el límite superior real.

Si el algoritmo asumiera que la capacidad máxima del proveedor es exactamente igual a sus ventas históricas máximas, sobreestimaría el riesgo de manera artificiosa, estaría asumiendo que el proveedor nunca puede surtir más de lo que ya surtió, sin margen de elasticidad operativa. En su lugar, se otorga un buffer mínimo:

```
Capacidad_latente = Ventas_historicas x 1.05
```

El +5% representa la holgura operativa mínima que cualquier proveedor razonablemente puede activar ante un incremento de demanda, horas extra, optimización de línea de producción, reducción de tiempos de setup, sin requerir inversión de capital adicional. Es una estimación conservadora que evita sobreestimar el riesgo sin subestimarlo.

4.3 Semilla Aleatoria Determinista para Reproducibilidad

En cualquier análisis científico o de negocio, la reproducibilidad es un requisito fundamental: dos personas que corran el mismo código con los mismos datos deben obtener exactamente los

mismos resultados. Sin una semilla fija, el generador de números pseudoaleatorios produce secuencias distintas en cada ejecución, haciendo imposible la auditoría de resultados.

El modelo usa dos semillas fijas:

- `rng = np.random.default_rng(seed=42)` para todas las simulaciones de demanda y capacidad por proveedor.
- `rng = np.random.default_rng(seed=123)` para todas las simulaciones del análisis de transferencia de volumen entre proveedores.

Estas semillas garantizan que cada ejecución del pipeline produce exactamente los mismos 10,000 escenarios, los mismos porcentajes de desabasto y las mismas recomendaciones de stock de seguridad, condición necesaria para que el equipo de compras pueda auditar y confiar en los números del reporte.

5. Hallazgos y Análisis Operativo

5.1 Radiografía Histórica de Riesgo del Portafolio (2023–2025)

La primera salida del pipeline es la tabla de riesgo histórico que clasifica los 33 proveedores activos en tres niveles basándose en su comportamiento real durante julio 2023 – diciembre 2025. El portafolio presenta una distribución equilibrada (11 proveedores por nivel) con alta heterogeneidad: el Fulfillment Rate oscila entre 77.7% (PROV44) y 99.5% (PROV33), una brecha de 21.8 puntos porcentuales.

Estadísticas del portafolio completo:

- Fulfillment Rate promedio del portafolio: 95.6%
- Peor Fulfillment Rate: 77.7% (PROV44), casi 1 de cada 4 unidades demandadas sin surtir
- Mejor Fulfillment Rate: 99.5% (PROV33), solo 5 de cada 1,000 unidades demandadas sin surtir
- Stock de Seguridad total recomendado para todo el portafolio Jul-Dic 2026: 75,188,209 unidades
- Probabilidad de desabasto promedio en toda la temporada: 55.2%

La tabla completa del portafolio, ordenada de mayor a menor riesgo:

Proveedor	Ventas Totales	Fulfillment Rate	Tasa Negados	Score Riesgo	Nivel
PROV44	46,246	77.7%	22.3%	0.2483	ALTO
PROV16	65,428	82.8%	17.2%	0.2191	ALTO
PROV7	45,752	85.2%	14.8%	0.1895	ALTO
PROV48	1,313,405	96.3%	3.7%	0.1745	ALTO
PROV9	4,364,533	98.7%	1.3%	0.1655	ALTO
PROV26	18,960	89.6%	10.4%	0.1559	ALTO
PROV42	6,302,769	98.8%	1.2%	0.1547	ALTO
PROV20	803,991	95.9%	4.1%	0.1413	ALTO
PROV13	3,852,489	97.6%	2.4%	0.1379	ALTO
PROV37	402,136	95.8%	4.2%	0.1359	ALTO
PROV11	7,124,582	97.4%	2.6%	0.1304	ALTO
PROV27	2,825,888	94.2%	5.8%	0.1261	MEDIO
PROV36	6,097,460	97.1%	2.9%	0.1254	MEDIO
PROV21	2,219,535	97.3%	2.7%	0.1230	MEDIO
PROV47	14,158,594	98.3%	1.7%	0.1213	MEDIO

PROV29	121,756	91.0%	9.0%	0.1210	MEDIO
PROV41	992,280	95.3%	4.7%	0.1190	MEDIO
PROV15	4,172,915	98.7%	1.3%	0.1101	MEDIO
PROV25	2,523,771	98.4%	1.6%	0.1081	MEDIO
PROV24	172,309	93.7%	6.3%	0.1047	MEDIO
PROV14	3,382,268	99.2%	0.8%	0.1044	MEDIO
PROV5	3,450,433	96.7%	3.3%	0.1044	MEDIO
PROV19	4,428,811	97.8%	2.2%	0.1037	BAJO
PROV32	5,389,012	96.4%	3.6%	0.1020	BAJO
PROV34	1,759,027	97.1%	2.9%	0.0916	BAJO
PROV23	878,021	99.0%	1.0%	0.0876	BAJO
PROV28	32,506	96.9%	3.1%	0.0857	BAJO
PROV2	1,046,413	99.4%	0.6%	0.0804	BAJO
PROV3	841,955	99.0%	1.0%	0.0749	BAJO
PROV17	1,344,498	99.3%	0.7%	0.0705	BAJO
PROV33	1,257,336	99.5%	0.5%	0.0682	BAJO
PROV31	109,443	96.0%	4.0%	0.0666	BAJO
PROV1	31,912	98.5%	1.5%	0.0503	BAJO

Una observación importante sobre la clasificación: algunos proveedores con Fulfillment Rate aparentemente alto quedan clasificados como ALTO riesgo (por ejemplo, PROV9 con 98.7% FR). Esto ocurre porque el score considera también el Coeficiente de Variación, la volatilidad de su demanda. PROV9, a pesar de su buen FR agregado, presenta alta irregularidad mes a mes, lo que lo hace difícil de planear y lo categoriza como riesgo alto en el scoring compuesto.

5.2 El Hallazgo Estratégico: Complejidad de Manufactura vs. Especialización

Al cruzar los outputs del scoring de riesgo con la dimensión MODELO del dataset (número de modelos distintos de calzado que fabrica cada proveedor), emerge el insight estratégico más importante del estudio: la causa raíz del desabasto crónico no es la falta de capacidad bruta de producción, sino el costo de complejidad derivado de fabricar demasiados modelos simultáneamente.

Los Proveedores de Alto Riesgo: Alta Complejidad

Los 11 proveedores clasificados como ALTO riesgo fabrican entre 8 y 19 modelos diferentes de calzado de manera simultánea. Esta diversidad de SKUs genera múltiples fricciones operativas en su proceso de producción:

- Setup times elevados: cada cambio de modelo en la línea de producción requiere tiempo de preparación (cambio de moldes, hormas, materiales). Con 15–19 modelos distintos, la línea de producción pasa una fracción significativa del tiempo cambiando entre modelos en lugar de produciendo.
- Rotación de moldes y hormas: cada modelo de calzado requiere herramental específico (moldes para la suela, hormas para la forma del zapato). Mantener, almacenar y rotar ese herramental para 15–19 modelos es logísticamente complejo y propenso a errores.
- Fragmentación de corridas de producción: con muchos modelos, cada lote de producción es más pequeño. Los lotes pequeños son menos eficientes por unidad (pérdida de economías de escala) y más susceptibles a variaciones de calidad.
- Mayor probabilidad de error de planeación: pronosticar la demanda para 15–19 modelos simultáneamente es mucho más difícil que para 1–4 modelos, aumentando la probabilidad de sobreproducir unos y subproducir otros.

El Pool Estrella: Hiper-Especialización

Los tres proveedores con mejor desempeño histórico comparten una característica estructural que los distingue radicalmente del resto del portafolio: cada uno fabrica exclusivamente 1 modelo de calzado, y ninguno comparte SKUs con los demás ni con el resto de la red.

- PROV33: 1 modelo exclusivo. Fulfillment Rate histórico: 99.48%. No comparte SKUs con ningún otro proveedor de la red.
- PROV31: 1 modelo exclusivo. Fulfillment Rate histórico: 96.05%. No comparte SKUs con ningún otro proveedor de la red.
- PROV1: 1 modelo exclusivo. Fulfillment Rate histórico: 98.52%. No comparte SKUs con ningún otro proveedor de la red.

La hiper-especialización permite a estos proveedores mantener líneas de producción continuas sin interrupciones por cambio de modelo, optimizar su herramental para un solo producto, planear la demanda con mayor precisión y alcanzar economías de escala plenas en su único modelo. El resultado es una confiabilidad de entrega que supera el 96% en los tres casos.

Este hallazgo tiene implicaciones estratégicas directas: el problema de desabasto de la empresa no se resuelve solo negociando más inventario de seguridad con los proveedores actuales, se resuelve estructuralmente desarrollando y priorizando proveedores especializados en la asignación de volumen.

5.3 Predicción Monte Carlo Jul–Dic 2026: Análisis Mes Crítico por Proveedor

Para cada uno de los 33 proveedores, el pipeline simula 10,000 escenarios de demanda vs. capacidad para cada uno de los 6 meses de la temporada. La siguiente tabla presenta el mes de mayor riesgo de desabasto por proveedor junto con el stock de seguridad recomendado (P95) para

ese mes. Los proveedores están ordenados de mayor a menor probabilidad de desabasto en su mes crítico:

Proveedor	Mes Crítico	Prob. Desabasto	SS Recomendado (P95)
PROV44	Dic	100.0%	11,966 u
PROV16	Dic	99.9%	16,197 u
PROV11	Nov	99.7%	1,740,575 u
PROV7	Dic	98.2%	10,328 u
PROV14	Nov	97.6%	676,139 u
PROV29	Dic	95.1%	14,923 u
PROV47	Dic	92.4%	2,771,864 u
PROV26	Dic	91.4%	3,509 u
PROV48	Dic	89.0%	490,734 u
PROV19	Nov	88.9%	3,345,373 u
PROV42	Ago	88.6%	765,087 u
PROV13	Nov	86.2%	1,362,673 u
PROV27	Dic	85.9%	228,930 u
PROV9	Nov	84.9%	1,683,046 u
PROV37	Nov	83.5%	153,997 u
PROV15	Nov	82.8%	2,221,112 u
PROV36	Nov	80.1%	3,646,201 u
PROV24	Dic	77.2%	20,126 u
PROV28	Jul	77.0%	292 u
PROV20	Oct	71.4%	159,255 u
PROV41	Nov	65.4%	71,273 u
PROV31	Ago	65.3%	4,602 u
PROV34	Jul	63.2%	40,549 u
PROV5	Ago	63.0%	108,842 u
PROV21	Oct	61.2%	315,232 u
PROV32	Nov	57.0%	339,734 u
PROV25	Dic	48.8%	146,777 u
PROV1	Jul	45.0%	397 u
PROV23	Dic	41.7%	67,701 u

PROV2	Dic	41.4%	60,132 u
PROV17	Ago	41.3%	34,400 u
PROV3	Nov	41.3%	38,838 u
PROV33	Oct	39.6%	37,358 u

Observaciones clave de esta tabla:

- Diciembre y Noviembre son los meses de mayor concentración de riesgo: 12 de los 33 proveedores tienen su mes crítico en Diciembre y 10 en Noviembre. Esto es consistente con el patrón estacional del sector calzado en México, donde las compras de fin de año (Navidad, posadas, temporada fría) concentran la demanda máxima.
- Existe una categoría de proveedores con probabilidad de desabasto del 95–100% en su mes crítico (PROV44, PROV16, PROV11, PROV7, PROV14, PROV29). Para estos proveedores, el desabasto en ese mes no es un riesgo, es una certeza estadística bajo el modelo actual de abastecimiento.
- El pool estrella (PROV33, PROV31, PROV1) mantiene probabilidades de desabasto significativamente menores al promedio del portafolio (55.2%): 39.6%, 65.3% y 45.0% respectivamente en sus meses críticos. Sus volúmenes de SS recomendados son también mucho menores, confirmando su estabilidad operativa.
- La disparidad en Stock de Seguridad es enorme: PROV19 requiere 3,345,373 unidades de SS en Noviembre, mientras PROV26 solo requiere 3,509 unidades en Diciembre. Esta variación de tres órdenes de magnitud refleja diferencias fundamentales en el tamaño y volatilidad de cada proveedor.

5.4 Stock de Seguridad Total por Proveedor: Temporada Completa Jul–Dic 2026

La siguiente tabla presenta el stock de seguridad total recomendado sumando los 6 meses de la temporada por proveedor. Esta es la cifra que determina la inversión en inventario de protección para cada relación comercial:

Proveedor	SS Total Jul-Dic 2026 (unidades)	Nivel Riesgo
PROV36	11,379,761	MEDIO
PROV42	10,999,941	ALTO
PROV47	9,766,342	MEDIO
PROV19	8,357,750	BAJO
PROV15	8,169,755	MEDIO
PROV9	5,118,270	ALTO
PROV11	4,611,437	ALTO
PROV13	4,106,502	ALTO

PROV14	2,418,693	MEDIO
PROV21	2,395,096	MEDIO
PROV48	1,495,650	ALTO
PROV32	1,249,986	BAJO
PROV20	825,679	ALTO
PROV5	786,216	MEDIO
PROV27	733,445	MEDIO
PROV25	526,715	MEDIO
PROV34	392,951	BAJO
PROV37	344,572	ALTO
PROV17	267,113	BAJO
PROV33	246,804	BAJO
PROV41	243,963	MEDIO
PROV2	207,043	BAJO
PROV23	177,256	BAJO
PROV3	169,489	BAJO
PROV24	45,848	MEDIO
PROV29	36,647	MEDIO
PROV16	27,803	ALTO
PROV31	25,878	BAJO
PROV44	23,877	ALTO
PROV7	17,678	ALTO
PROV28	7,349	BAJO
PROV1	6,615	BAJO
PROV26	6,085	ALTO

Nota importante: el SS total no correlaciona perfectamente con el nivel de riesgo porque también depende del volumen de ventas del proveedor. PROV36 y PROV47 (nivel MEDIO) tienen los mayores SS totales porque son proveedores de alto volumen, aunque su tasa de negados no sea la peor del portafolio, la magnitud de sus ventas amplifica el SS recomendado. PROV44 (nivel ALTO, peor FR del portafolio) tiene SS total bajo porque es un proveedor de bajo volumen.

5.5 Casos de Negocio: Simulación de Transferencia de Volumen

El análisis what-if cuantifica matemáticamente el impacto de transferir parte de la demanda actualmente asignada a proveedores de alto riesgo hacia el pool estrella (PROV33, PROV31 o PROV1). La simulación reutiliza los 10,000 escenarios de exceso del proveedor de alto riesgo y los confronta con la capacidad simulada del proveedor estrella para calcular el exceso residual, las unidades que el proveedor estrella no podría absorber del déficit original.

La tabla de transferencias completa, ordenada por volumen de ventas potencialmente recuperado en la temporada completa Jul–Dic 2026:

Proveedor Origen	Transferir a	Volumen Salvado Jul-Dic 2026
PROV11	PROV33	948,695 unidades
PROV9	PROV33	762,268 unidades
PROV13	PROV33	752,667 unidades
PROV42	PROV33	654,149 unidades
PROV48	PROV33	498,548 unidades
PROV20	PROV33	238,454 unidades
PROV37	PROV33	112,758 unidades
PROV11	PROV31	98,204 unidades
PROV13	PROV31	80,205 unidades
PROV9	PROV31	79,651 unidades
PROV48	PROV31	77,301 unidades
PROV42	PROV31	73,775 unidades
PROV20	PROV31	63,692 unidades
PROV37	PROV31	52,048 unidades
PROV11	PROV1	27,705 unidades

El 'volumen salvado' es el proxy cuantitativo del ROI de la negociación estratégica: representa las unidades de demanda que actualmente se pierden por incapacidad del proveedor de alto riesgo y que serían cubiertas si ese volumen se redirigiera al proveedor estrella. No es el volumen total transferido, es el delta en exceso de demanda no cubierto, antes y después de la transferencia.

Hallazgos clave del análisis de transferencias:

- PROV33 es el destino más rentable en todos los casos, su combinación de alta capacidad y baja variabilidad lo convierte en el absorbedor más eficiente de exceso de demanda.
- PROV11→PROV33 es el caso de negocio de mayor impacto individual: 948,695 unidades recuperables en la temporada. Esto equivale aproximadamente a 158,116 unidades por mes, un volumen operativamente significativo para negociar con PROV33.

- PROV31 y PROV1 tienen capacidad de absorción más limitada (volúmenes salvados menores), consistente con sus menores ventas históricas. Sin embargo, contribuyen como opciones complementarias de diversificación.
- La estrategia óptima no es elegir un solo par de transferencia, sino construir un plan escalonado: primero maximizar la transferencia hacia PROV33 (mayor capacidad), luego complementar con PROV31 y PROV1 para los excesos residuales.

6. Recomendaciones Tácticas y Estratégicas

6.1 Acciones Tácticas Inmediatas (Jul–Dic 2026)

La tabla_prediccion_2026.csv funciona como una lista de compras cuantificada mes a mes. Para cada proveedor en cada mes, el Stock de Seguridad recomendado (P95) define el inventario adicional que debe negociarse por encima del pedido base para garantizar el nivel de servicio del 95%.

Los cinco proveedores que requieren atención prioritaria por concentrar el mayor volumen de SS total recomendado para la temporada son:

- PROV36: 11,379,761 unidades de SS total. Prioridad máxima. Aunque es nivel MEDIO de riesgo, su alto volumen de ventas hace que cualquier falla tenga impacto masivo.
- PROV42: 10,999,941 unidades. Proveedor de alto volumen con riesgo ALTO, combinación de mayor impacto potencial.
- PROV47: 9,766,342 unidades. El proveedor de mayor volumen de ventas del portafolio (14.1M unidades históricas). Su nivel MEDIO de riesgo con ese volumen justifica SS prioritario.
- PROV19: 8,357,750 unidades. Nivel BAJO de riesgo pero alto volumen, el SS se dispara por la magnitud de las ventas.
- PROV15: 8,169,755 unidades. Nivel MEDIO con alto volumen.

Advertencia táctica: mantener inventario de seguridad de manera permanente inmoviliza capital de trabajo, genera costos de almacenamiento y aumenta el riesgo de obsolescencia (especialmente en calzado de temporada). La estrategia de SS es una solución de corto plazo necesaria, pero no sostenible como modelo permanente, lo que justifica la inversión en la estrategia de mediano plazo.

6.2 Plan Estratégico de Mediano Plazo: Desarrollo y Transferencia de Volumen

La solución estructural al problema de desabasto crónico no es comprar más inventario de seguridad, es rediseñar la asignación de volumen del portafolio de proveedores. El análisis de transferencias provee los argumentos cuantitativos para cada negociación.

Paso 1: Mesa de Desarrollo de Proveedores Estrella

Abrir formalmente una mesa de Desarrollo de Proveedores con PROV33, PROV31 y PROV1 para la temporada 2026–2027. En esta mesa:

- Presentar los volúmenes proyectados de demanda para Jul–Dic 2026 como base de negociación de capacidad adicional.
- Evaluar la capacidad máxima instalada de cada proveedor estrella y los tiempos de lead time para expansión.
- Ofrecer contratos de volumen garantizado a cambio de compromisos de Fulfillment Rate mínimo del 97%.

Paso 2: Identificación de Modelos Transferibles

Cruzar la tabla de transferencias con la estructura de modelos de los proveedores de alto riesgo para identificar qué SKUs específicos son más viables de redirigir:

- Modelos de mayor rotación asignados a PROV11, PROV9 y PROV13 son los candidatos prioritarios (mayor impacto de volumen si se transfieren).
- Validar que el pool estrella puede producir esos modelos o modelos equivalentes sin comprometer su actual especialización.

Paso 3: Implementación de SLAs Basados en Datos

Implementar contratos de desempeño (Service Level Agreements) que incluyan:

- Fulfillment Rate mínimo del 97% medido mensualmente, con penalizaciones contractuales por incumplimiento.
- Notificación anticipada de riesgo de desabasto (mínimo 4 semanas antes del inicio de temporada).
- Derecho de la empresa a redistribuir volumen hacia proveedores alternativos si el proveedor principal incumple el SLA en dos meses consecutivos.

Paso 4: Comité de Revisión Trimestral

Establecer un comité de revisión cada trimestre para actualizar las simulaciones con los datos de ventas y negados más recientes. Esto permite ajustar los SS recomendados conforme avanza el año y detectar cambios en el comportamiento de los proveedores antes de que se conviertan en crisis de desabasto.

6.3 Limitación Operativa de la Recomendación de Transferencia

Es fundamental señalar que el análisis de transferencia de volumen parte de un supuesto no verificado con los datos disponibles: que el pool estrella tiene capacidad instalada suficiente para absorber el volumen adicional propuesto.

Los datos transaccionales de la empresa solo registran ventas y negados; no incluyen información sobre la capacidad máxima de producción de cada proveedor, los tiempos de expansión de línea, los costos de escalar producción ni los posibles conflictos con otros clientes del mismo proveedor.

La tabla de transferencias provee los casos de negocio (el qué y el cuánto), pero la ingeniería de manufactura y la gestión de proveedores deben confirmar la factibilidad operativa (el cómo) mediante evaluaciones directas con PROV33, PROV31 y PROV1 antes de comprometer volúmenes en contratos formales.

7. Limitaciones del Estudio y Líneas de Mejora Futura

7.1 Limitaciones Actuales

El modelo entrega valor operativo real con los datos disponibles, pero su precisión está acotada por varias limitaciones que deben entenderse antes de usar las recomendaciones:

- Muestra temporal $N = 3$ por celda: con solo 3 observaciones históricas por proveedor-mes, las distribuciones ajustadas son estimaciones con alta incertidumbre. Los intervalos P5-P95 son amplios precisamente porque el modelo cuantifica honestamente esa incertidumbre, pero esto también significa que el Stock de Seguridad P95 puede ser considerablemente diferente al valor real necesario.
- Tipo de negado no especificado: el dataset no distingue entre negados por falta de stock del proveedor y negados por error interno de planeación de la orden de compra. El modelo asume que toda la responsabilidad del negado recae en la capacidad del proveedor, lo cual puede sobreestimar el riesgo de aquellos proveedores cuyas fallas son en realidad errores de pedido de la empresa.
- Ausencia de regresores exógenos: el modelo no incorpora variables que tienen impacto documentado en la demanda de calzado: inflación y tipo de cambio (para botas importadas), severidad del invierno (demanda de botas correlaciona con temperatura), calendarios de quincena y periodos de aguinaldo, campañas de marketing y promociones.
- Granularidad de SKU no utilizada: el análisis opera a nivel proveedor total. Desagregar por modelo de zapato dentro de cada proveedor permitiría recomendaciones de SS por SKU, pero requeriría 6–10 años de historia para ser estadísticamente estable dado el mayor número de celdas a modelar.
- Capacidad instalada del pool estrella no observable: el análisis de transferencias asume que PROV33, PROV31 y PROV1 tienen capacidad ilimitada de absorción, supuesto que requiere validación operativa directa antes de actuar sobre las recomendaciones.
- Correlación entre proveedores no modelada: el pipeline trata a cada proveedor de manera independiente. En la realidad, algunos proveedores pueden compartir materias primas, proveedores de insumos o capacidad de manufactura subcontratada; una disrupción sistémica (como una escasez de cuero) afectaría a múltiples proveedores simultáneamente, escenario que el modelo actual no captura.

7.2 Líneas de Mejora Futura

- Pipeline rolling trimestral: incorporar datos de 2026 conforme se generan para actualizar simulaciones y ajustar SS recomendados en tiempo real. Con 2 trimestres adicionales de historia ($N = 5$), la precisión mejora notablemente.
- Dimensión de costo unitario: añadir el precio de compra por unidad para transformar el SS recomendado en unidades a SS recomendado en pesos, habilitando análisis de ROI directo (costo de mantener SS vs. valor de ventas protegidas).
- Clasificación de causa de negado: implementar un campo en el sistema transaccional que distinga si el negado fue por falta de stock del proveedor o por error de planeación de la orden de compra, para desagregar la responsabilidad correctamente.

- Distribuciones de cola pesada: explorar distribuciones Pareto o Log-Normal para proveedores con alta varianza histórica, que pueden ajustarse mejor a la asimetría extrema de algunos patrones de demanda.
- Modelo de correlación entre proveedores: incorporar una matriz de correlación de Spearman entre las tasas de negados de los proveedores para simular escenarios donde múltiples proveedores fallan simultáneamente (stress testing del portafolio).
- Desagregación por SKU: con suficiente historia, extender el análisis a nivel proveedor-modelo-mes para generar recomendaciones de SS granulares por producto.

8. Glosario de Términos Técnicos

Término	Definición
AIC	Criterio de Información de Akaike. Métrica estadística para comparar modelos que penaliza la complejidad (número de parámetros) para evitar sobreajuste.
Alpha (alpha)	Hiperparámetro del Score de Riesgo. Controla el peso relativo entre Tasa de Negados y Coeficiente de Variación. Valor óptimo: 0.95.
Cap de exceso	Límite superior aplicado al exceso simulado: máximo 5 veces la media histórica mensual. Previene que escenarios de cola extrema distorsionen el P95.
CV (Coef. Variación)	Desviación estándar dividida entre la media de la demanda histórica. Mide la volatilidad relativa del proveedor mes a mes.
Datos censurados	Observaciones donde el valor real está truncado por una restricción externa. En este contexto: ventas observadas < demanda real porque el stock se agotó.
Distribución Gamma	Familia de distribuciones de dominio positivo con asimetría positiva. Estándar en gestión de inventarios estocásticos.
Distribución Normal	Distribución simétrica de campana. Adecuada cuando los datos no presentan asimetría significativa.
FACTOR_NEGADOS	Parámetro de dominio (0.25) que determina qué fracción de los pedidos negados representa demanda real perdida vs. venta sustituida en tienda.
Fulfillment Rate	Porcentaje de la demanda total ajustada que fue efectivamente cubierta por el proveedor. $FR = \text{Ventas} / \text{Demanda_Real}$.
MLE	Estimación por Máxima Verosimilitud. Método para estimar los parámetros de una distribución estadística que maximizan la probabilidad de observar los datos disponibles.
Monte Carlo	Método de simulación que genera miles de escenarios aleatorios muestreando de distribuciones de probabilidad para cuantificar la incertidumbre de un sistema.
N_sim = 10,000	Número de iteraciones de simulación por proveedor-mes. Garantiza estabilidad estadística de los percentiles estimados (el error de estimación del P95 es < 1%).
Percentil 95 (P95)	El valor que 9,500 de los 10,000 escenarios simulados no superan. Umbral de cobertura seleccionado para el Stock de Seguridad.
Pool estrella	Los tres proveedores con mejor historial de cumplimiento: PROV33, PROV31 y PROV1. Cada uno fabrica 1 modelo exclusivo con FR > 96%.
Rho de Spearman	Coeficiente de correlación de rangos. Mide si el ordenamiento de riesgo entre proveedores se preserva entre periodos. Valor obtenido: rho = 0.30.
Score de Riesgo	Métrica compuesta que clasifica proveedores: $\text{Score} = 0.95 \times \text{Tasa_Negados} + 0.05 \times \text{CV}$.

Stock de Seguridad	Inventario adicional recomendado para cubrir la variabilidad entre demanda y capacidad del proveedor al nivel de servicio del 95%.
Tendencia acotada	Pendiente OLS de la demanda histórica, limitada al $\pm 20\%$ de la media para evitar proyecciones explosivas con $N = 3$.
Walk-Forward CV	Esquema de validación cruzada que respeta el orden temporal: siempre entrena en el pasado y valida en el futuro, simulando el uso real del modelo en producción.

9. Anexos: Entregables del Pipeline

El pipeline genera automáticamente los siguientes archivos de salida al ejecutarse:

9.1 Archivos CSV

- `tabla_riesgo_proveedores.csv`: Radiografía histórica completa de los 33 proveedores con score de riesgo, Fulfillment Rate, tasa de negados y clasificación por nivel. Base para priorización estratégica.
- `tabla_prediccion_2026.csv`: Predicción Monte Carlo mes a mes por proveedor para Jul-Dic 2026. Incluye demanda esperada, probabilidad de desabasto y stock de seguridad P95. Funciona como lista de compras cuantificada para el equipo de abastecimiento.
- `tabla_transferencia_estrategica.csv`: Casos de negocio por par proveedor-riesgo / proveedor-estrella. Cuantifica el volumen de ventas recuperables por cada posible transferencia de volumen.

9.2 Visualizaciones PNG

- `01_fulfillment_proveedores.png`: Gráfico de barras horizontales con el Fulfillment Rate histórico de los 33 proveedores, coloreado por nivel de riesgo (verde/amarillo/rojo).
- `03_prediccion_2026_PROVXX.png`: Dashboard de 3 paneles por proveedor (33 archivos): demanda esperada con intervalos P5-P95 vs. promedio histórico, probabilidad de desabasto por mes, y stock de seguridad recomendado por mes.
- `04_heatmap_prob_desabasto.png`: Mapa de calor (33 proveedores x 6 meses) con la probabilidad de desabasto de cada celda, escala de colores verde-amarillo-rojo.
- `05_heatmap_stock_seguridad.png`: Mapa de calor con el stock de seguridad P95 recomendado por proveedor-mes.
- `06_cross_validation_pesos.png`: Curva de optimización del hiperparámetro alpha con banda de incertidumbre ± 1 desviación estándar y línea vertical en el valor óptimo (0.95).